Inteligencia Artificial 2

Universidad Industrial de Santander

FaceCut AI

Clasificación de la forma del rostro masculino: **tres métodos de transfer learning** evaluados y comparados.



Integrantes

Héctor Julián Franco · **César David Ascencio** · **Carlos Andrés Gutiérrez**

Entrega 2

MTCNN + FaceNet · VGG16 · InceptionV3

La indecisión en las barberías

El problema

El cliente desconoce la estructura morfológica de su rostro y no sabe qué corte le favorece.

Impacto: la carga de decidir pasa al barbero, la atención se retrasa y el usuario queda insatisfecho.

Solución: FaceCut AI

Clasificación objetiva del rostro en cuatro morfologías masculinas mediante deep learning.

Salida: recomendación automática de uno a dos cortes ideales con un motor de reglas.



Morfologías objetivo Ovalado · Cuadrado · Redondo · Rectangular

Objetivo general y alcance del proyecto

Objetivo

Construir una herramienta que **clasifique cuatro tipos de rostro masculino** y aplique reglas de asociación directa para **sugerir los cortes más adecuados**.

MTCNN + FaceNet

VGG16

InceptionV3

Alcance técnico

1 **Modelado con deep learning**
Transfer learning sobre tres arquitecturas profundas, evaluadas en el mismo problema.

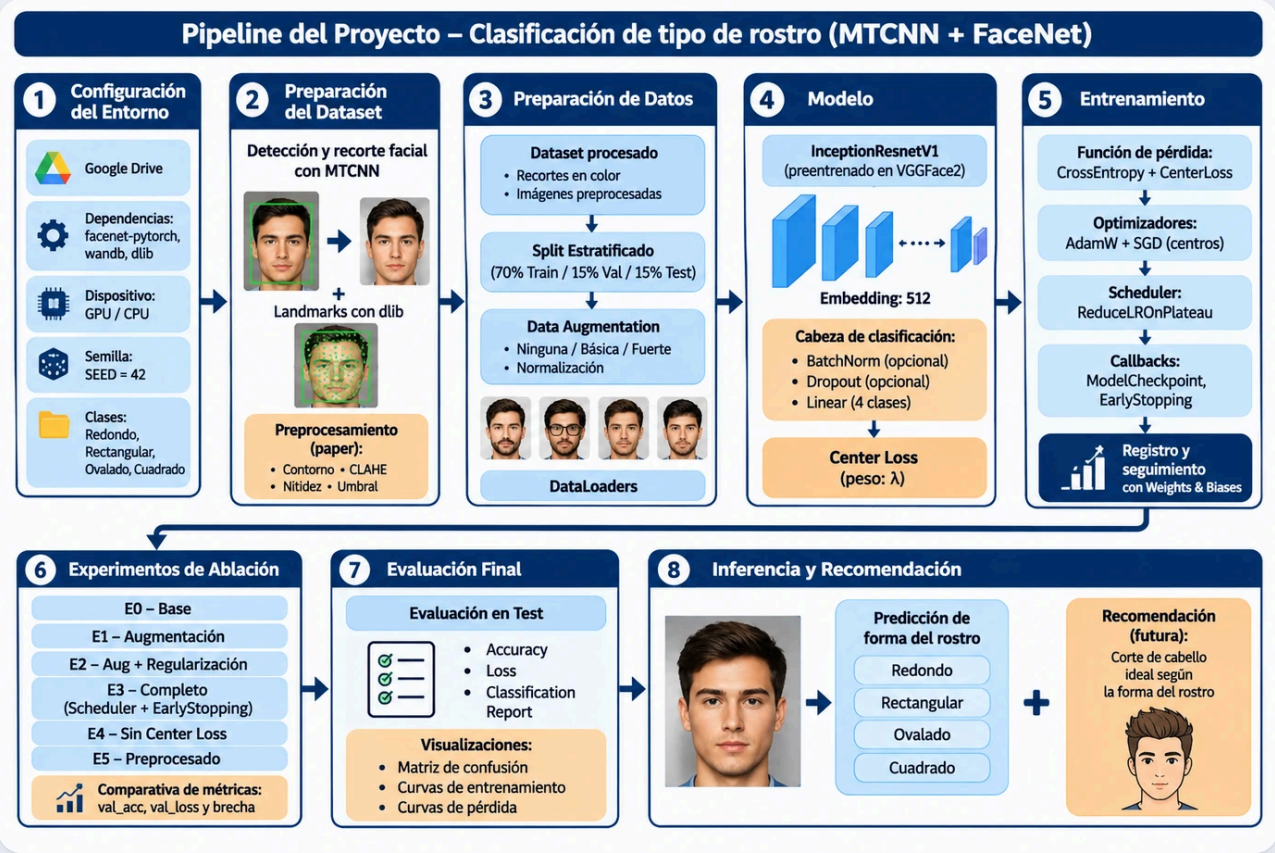
2 **Motor de reglas**
Lógica asociativa entre la morfología predicha y un catálogo de cortes.

3 **Despliegue y demo**
Pipeline de inferencia funcional en Google Colab.

Aporte clave: enfoque 100 % masculino, con aplicación comercial real en barberías.

MTCNN + FaceNet (Ji)

Método 1 de 3



Pipeline original Clic para ampliar

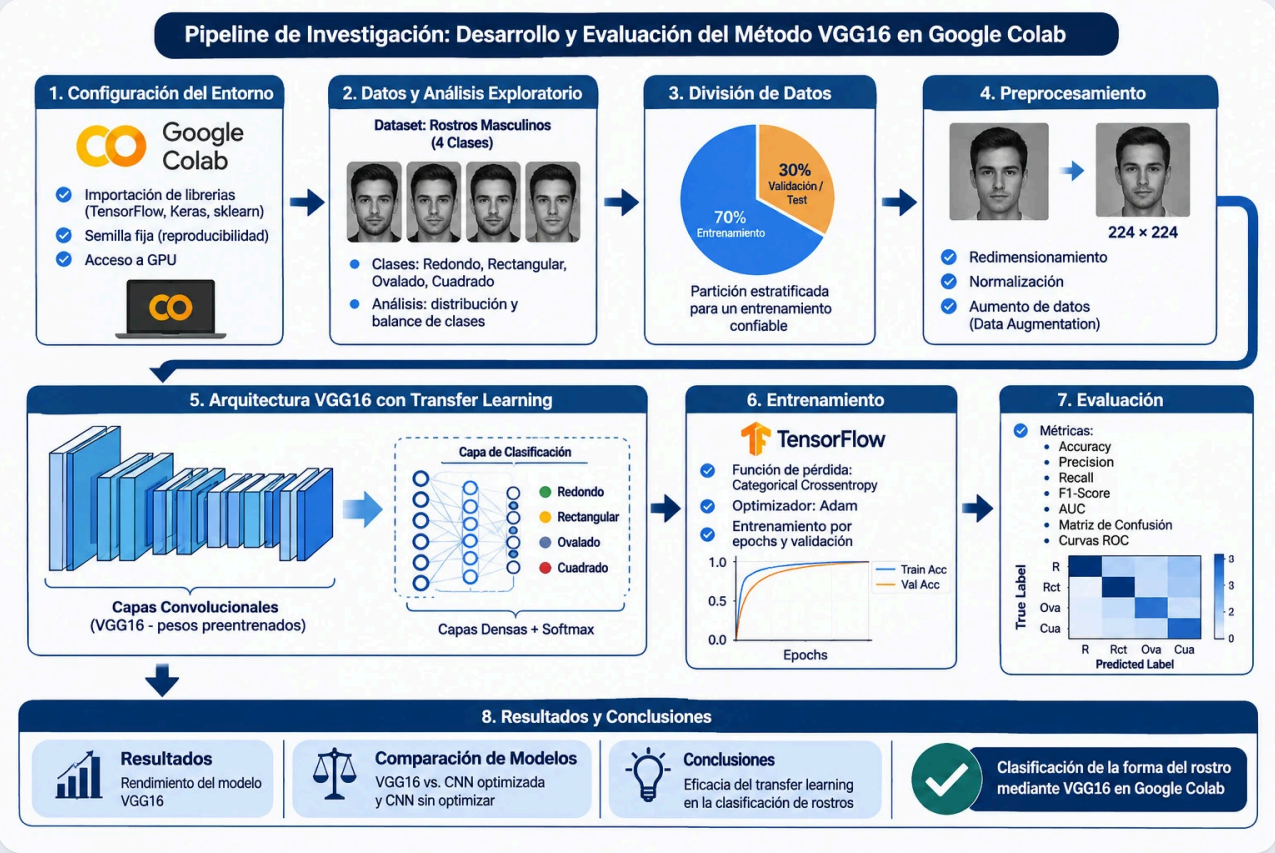
1 **Detección con MTCNN**
Recorte del rostro a color, 160 × 160 px.

2 **FaceNet como backbone**
InceptionResnetV1 preentrenado en VGGFace2; embedding de 512.

3 **Cabeza de 4 clases**
CrossEntropy + Center Loss, con ablación de E0 a E5.

Referencia: el artículo de Ji reporta 92.32 % de accuracy, por encima de DenseNet y VGG16.

VGG16 Método 2 de 3



Pipeline original Clic para ampliar

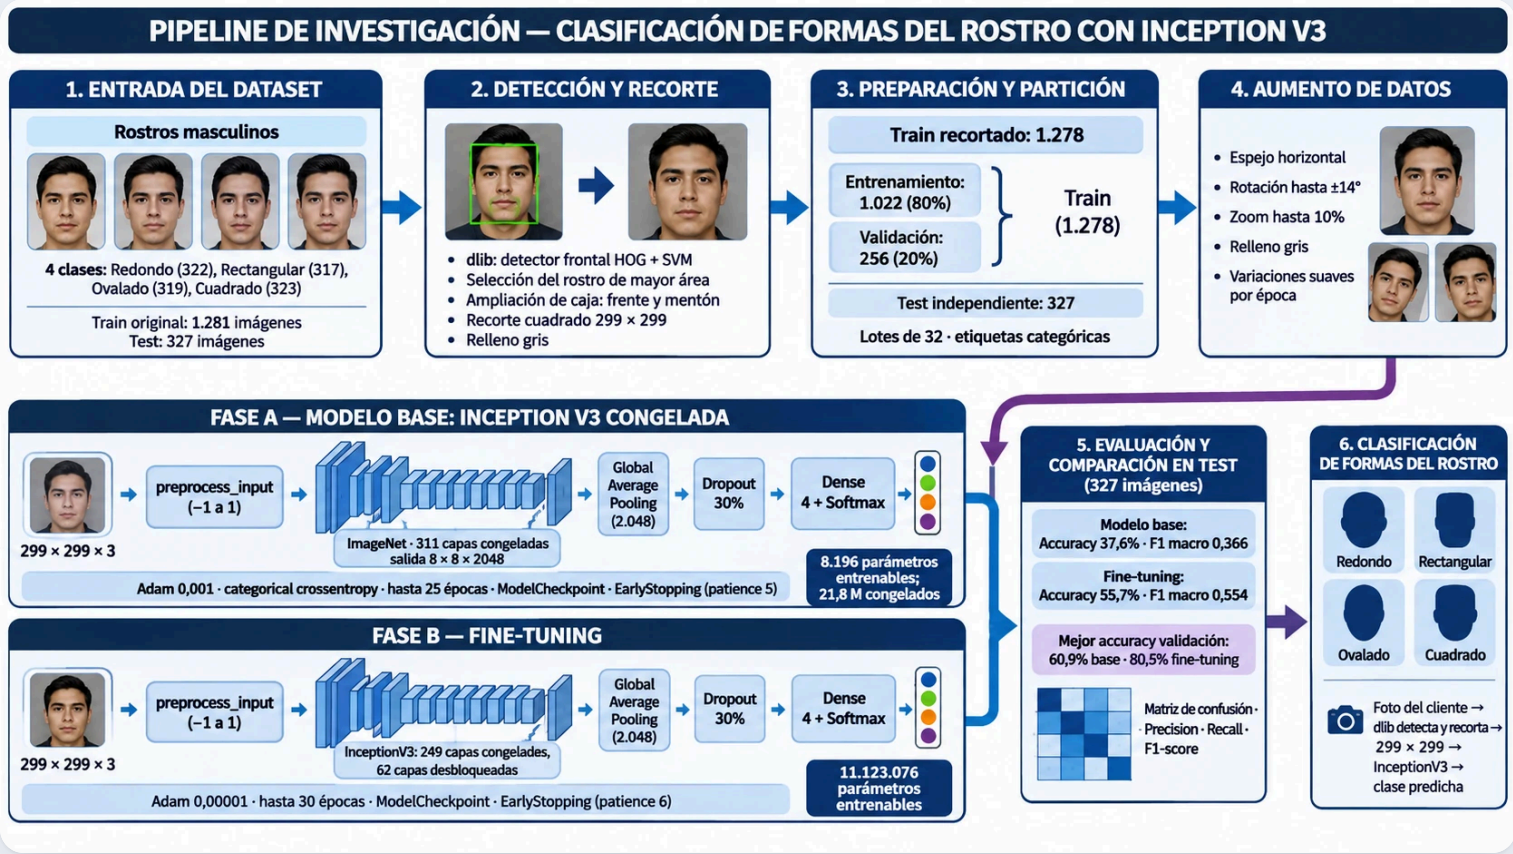
1 Preprocesamiento
Rostro con dlib, márgenes +15 % ancho y +50 % alto, 224 × 224 px.

2 Base congelada
VGG16 de ImageNet: 14.7 millones de pesos intactos.

3 Clasificador propio
Flatten, Dense 32 ReLU, Dropout 0.5 y Dense 4 Softmax.

Sin aumento de datos: decisión basada en el artículo VISCial, para no deformar los contornos faciales.

InceptionV3 Método 3 de 3



Pipeline original Clic para ampliar

1 Detección con dlib
HOG + SVM, recorte ampliado a 299 × 299 px y relleno gris.

A Fase A: base congelada
Solo 8,196 parámetros entrenables sobre 21.8 millones.

B Fase B: fine-tuning
Capas liberadas desde la 249: 11.1 millones de parámetros.

Aumento restrictivo: flip, rotación de 4° y zoom de 10 %, para no alterar la geometría del rostro.

Un mismo dataset, dos particiones

1,281 imágenes balanceadas de datasets públicos y recolección propia en Pinterest, homogeneizadas para los tres métodos.

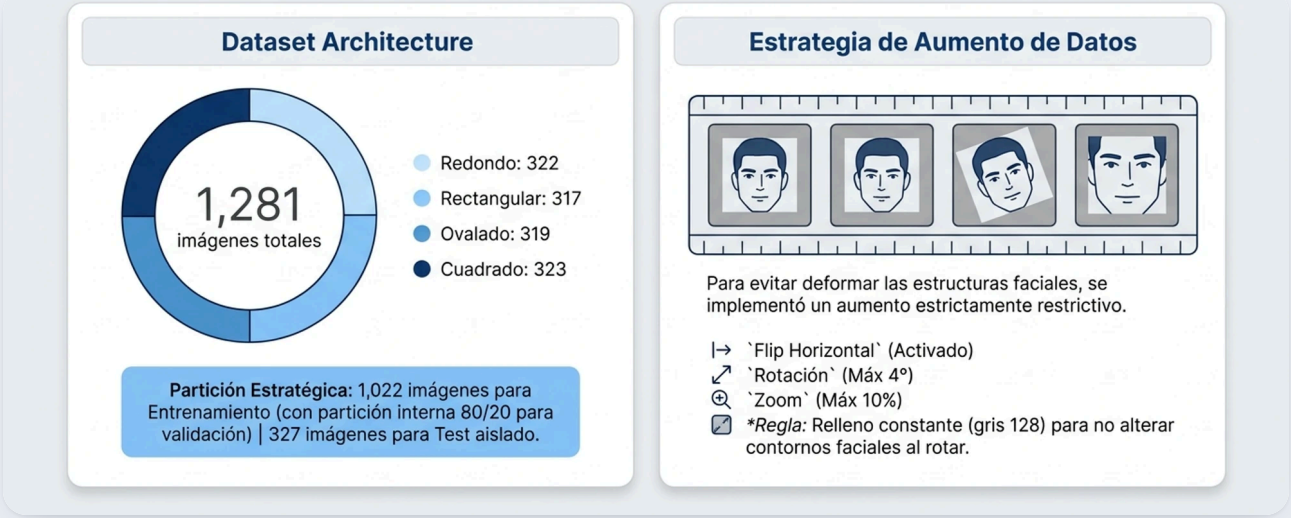


Figura original Arquitectura del dataset y aumento de datos

Partición por método

MÉTODO	PARTICIÓN	TEST
MTCNN + FaceNet	70 / 15 / 15 %	192
VGG16	1,022 train/val (80/20)	327
InceptionV3	1,022 train/val (80/20)	327

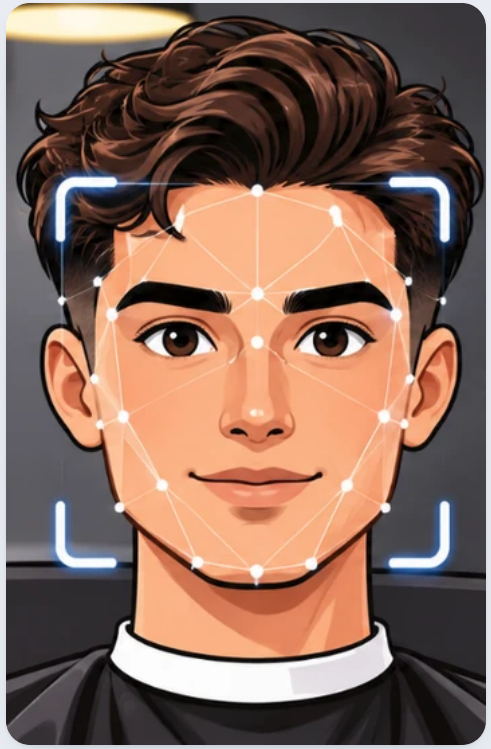
Las 327 imágenes de test quedaron aisladas del entrenamiento. FaceNet usó su propia partición estratificada de 48 imágenes por clase.

Configuración de cada método

	MTCNN + FaceNet	VGG16	InceptionV3
Entrada	Recorte MTCNN, 160 × 160	Recorte dlib, 224 × 224	Recorte dlib, 299 × 299
Preentrenamiento	VGGFace2 (rostros)	ImageNet	ImageNet
Entrenamiento	Backbone + cabeza	Solo la cabeza, una fase	Fase A congelada, fase B fine-tuning
Optimizador	AdamW: 2e-5 backbone, 1e-3 cabeza	Adam, 1e-4	Adam: 1e-3 (A), 1e-5 (B)
Pérdida	CrossEntropy + Center Loss (λ = 0.01)	*No reportada*	Categorical crossentropy
Batch / épocas	32 / 60 máx.	32 / 30 máx.	32 / 25 (A), 30 (B) máx.
Regularización	Dropout 0.5, BatchNorm, weight decay 1e-2, label smoothing 0.1	Dropout 0.5	Dropout 30 %
Aumento de datos	Flip, rotación ±10°, zoom, ColorJitter, RandomErasing	Ninguno	Flip, rotación 4°, zoom 10 %
Callbacks	ReduceLROnPlateau, Early Stopping (8), ModelCheckpoint	Early Stopping (5), ModelCheckpoint	Early Stopping (5 y 6), ModelCheckpoint
Métricas	Accuracy, P, R y F1 por clase, matriz de confusión, brecha train–val	Accuracy y 7 métricas por clase: CA, CE, SV, SF, FPR, P, F1	Accuracy, F1 macro, matriz de confusión

Entrenamiento: MTCNN + FaceNet

Método 1 de 3



Entrada
Recorte MTCNN a color, 160 × 160

Ajuste fino completo

Backbone y cabeza se entrenan juntos con **AdamW** y tasas diferenciadas: **2e-5** en el backbone para no destruir lo aprendido en VGGFace2 y **1e-3** en la cabeza.

Pérdida combinada

CrossEntropy + Center Loss (λ = 0.01): además de separar las clases, agrupa los embeddings de cada morfología alrededor de su centro.

Regularización y aumento

Dropout 0.5, BatchNorm, weight decay 1e-2 y label smoothing 0.1. Aumento con flip, rotación ±10°, zoom, ColorJitter y RandomErasing.

Control del entrenamiento

Batch de 32 y hasta 60 épocas, con ReduceLROnPlateau, Early Stopping de paciencia 8 y ModelCheckpoint.

Experimentos de ablación

- **E0** Base
- **E1** Aumentación
- **E2** Aumento + regularización
- **E3** Completo
- **E4** Sin Center Loss
- **E5** Preprocesado

Entrenamiento: VGG16 Método 2 de 3

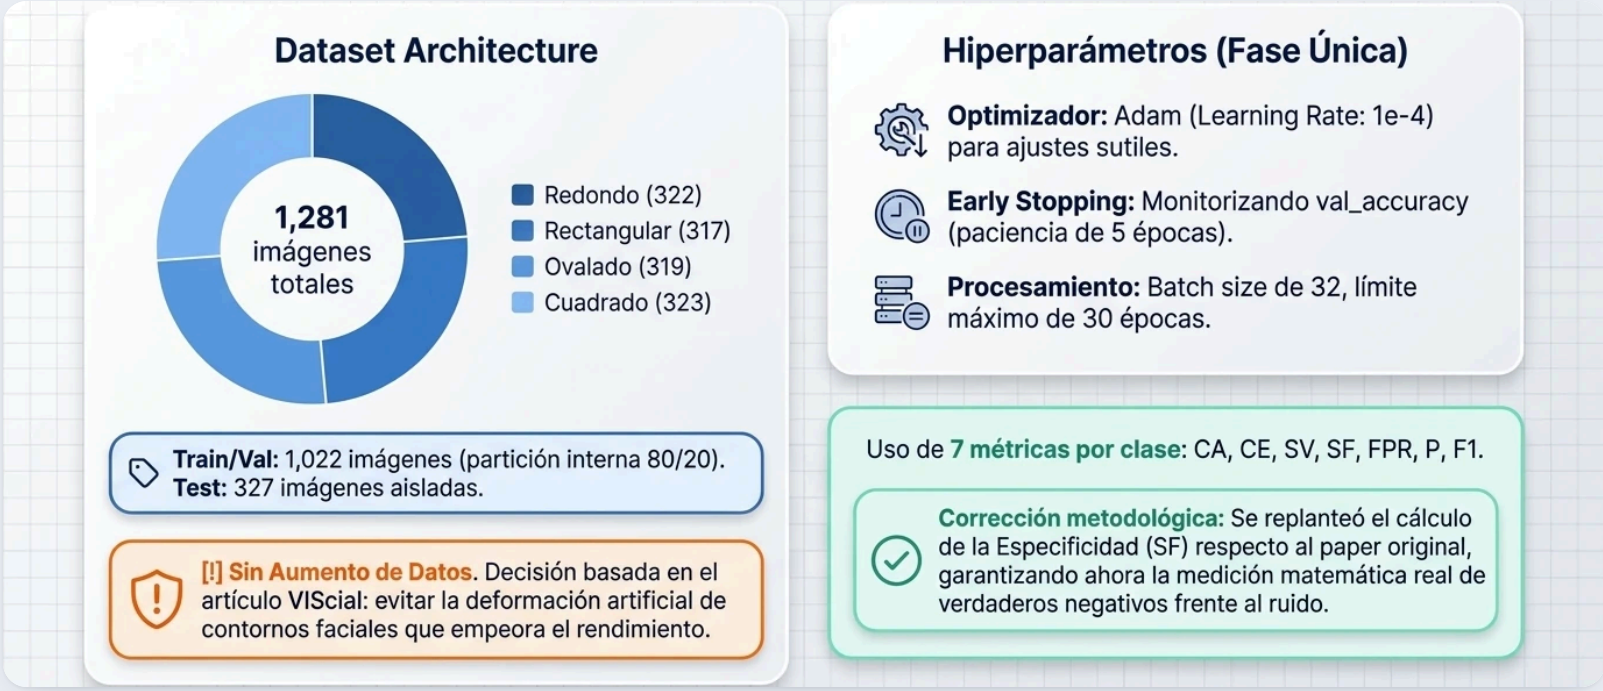


Figura original Configuración experimental de VGG16

1 **Fase única**
Solo se entrena el clasificador; la base VGG16 queda congelada.

2 **Adam, 1e-4**
Batch de 32, hasta 30 épocas, Early Stopping sobre val_accuracy con paciencia 5.

3 **Siete métricas por clase**
CA, CE, SV, SF, FPR, P y F1, con la especificidad recalculada.

Sin aumento de datos, para no deformar artificialmente los contornos faciales.

Entrenamiento: InceptionV3

Método 3 de 3

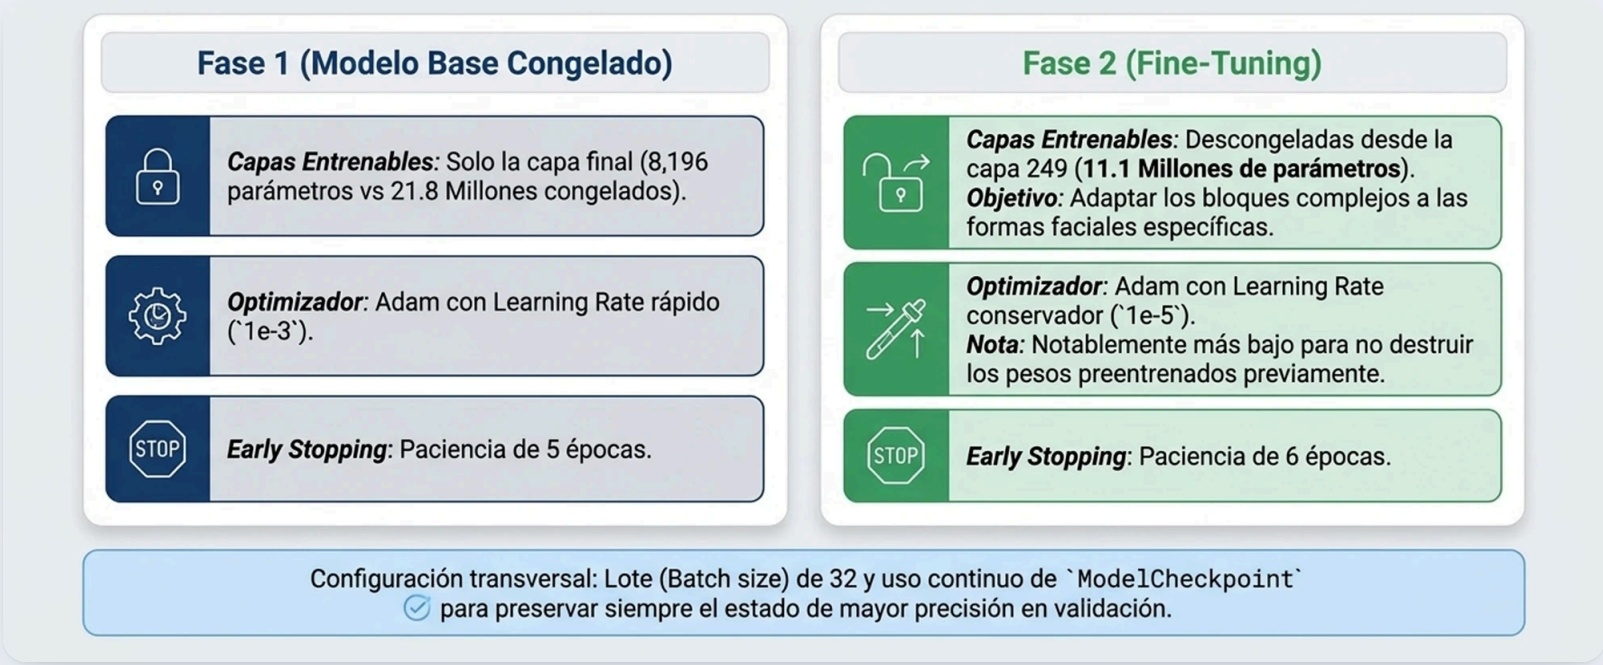
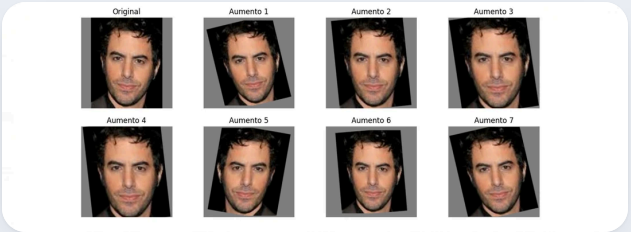


Figura original Transfer learning en dos fases



Aumento de datos
Relleno gris para no alterar los contornos

1 **Fase 1: base congelada**
Adam 1e-3, Early Stopping de paciencia 5.

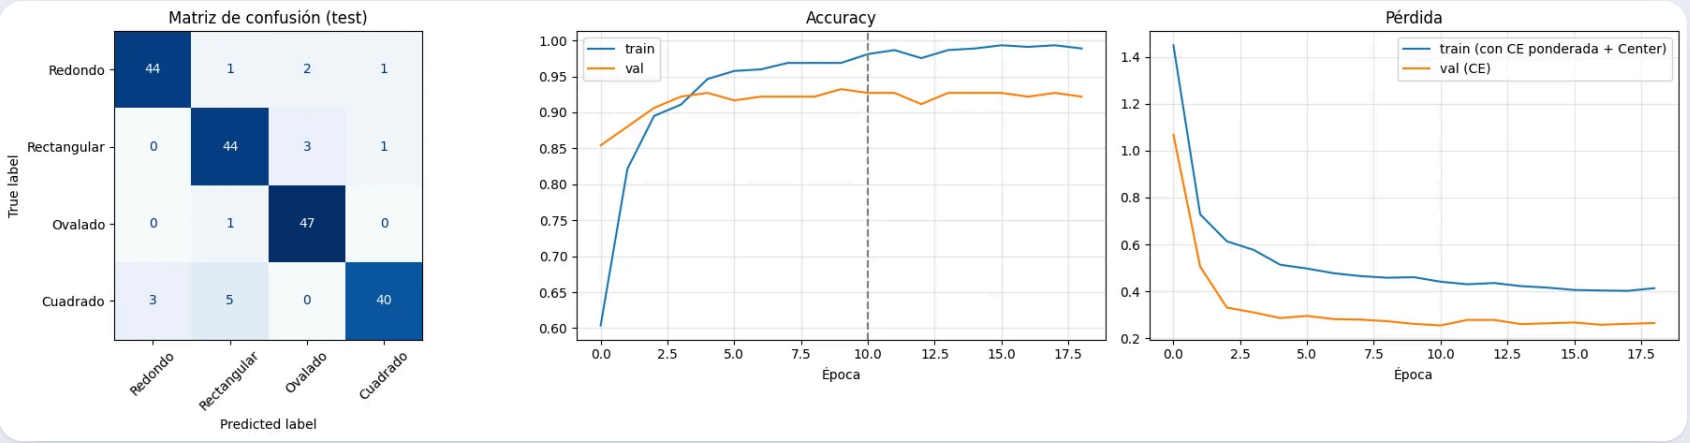
2 **Fase 2: fine-tuning**
Desde la capa 249, Adam 1e-5, Early Stopping de paciencia 6.

Resultados: MTCNN + FaceNet

Test, 192 imágenes

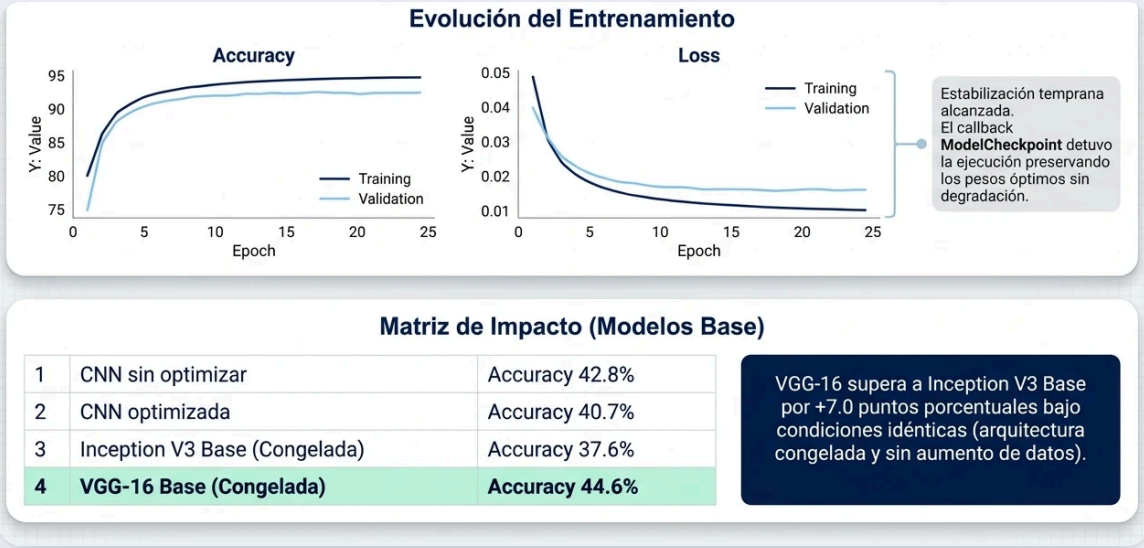
CLASE	PRECISION	RECALL	F1-SCORE	SUPPORT
Redondo	0.936	0.917	0.926	48
Rectangular	0.863	0.917	0.889	48
Ovalado	0.904	0.979	0.940	48
Cuadrado	0.952	0.833	0.889	48
Accuracy			0.911	192
Macro avg	0.914	0.911	0.911	192
Weighted avg	0.914	0.911	0.911	192

- **Accuracy de 91.1 %:** buena generalización y convergencia estable.
- **Destacan Ovalado y Redondo,** con F1-score superior a 0.92.
- **Reto: Cuadrado** (recall 0.833) se confunde con Rectangular por similitud geométrica.
- **Regularización:** las curvas muestran el sobreajuste bajo control.



Resultados: VGG16 Test, 327 imágenes

44.6 % de accuracy en test, siete puntos sobre InceptionV3 base, con una brecha de 0.470 entre entrenamiento y prueba: el modelo memorizó el dataset local.



Evolución del entrenamiento Comparación con modelos base



Análisis de errores por clase Redondo es la clase más débil

Resultados: InceptionV3 Test, 327 imágenes

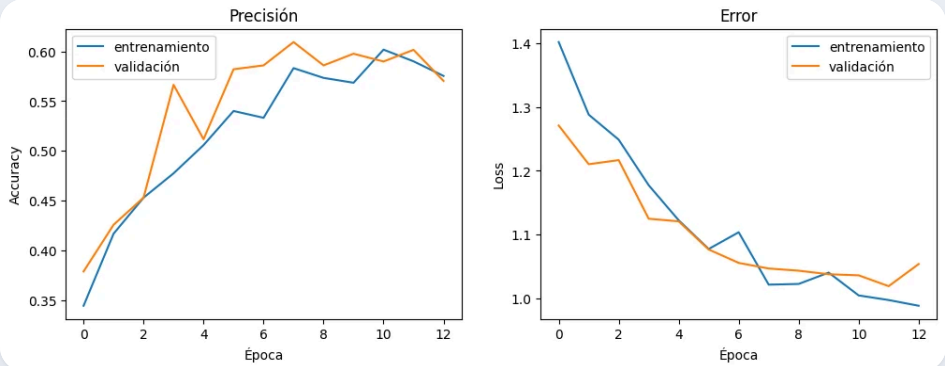
Impacto del Fine-Tuning

1	**Modelo Base**	Accuracy Test: **37.6%**	F1-Score: **0.36**
2	**Con Fine-Tuning**	Accuracy Test: **55.7%**	F1-Score: **0.55**

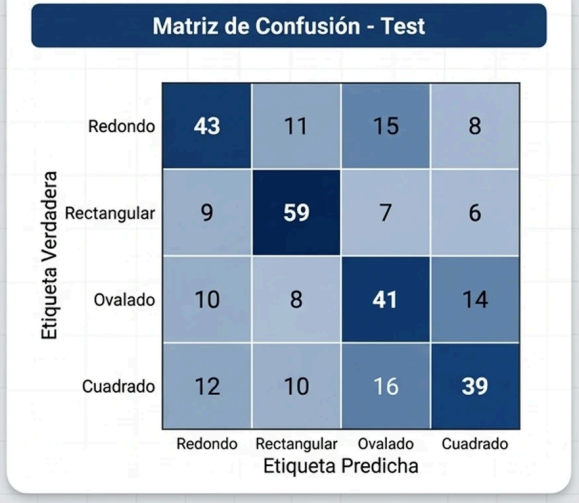
Conclusión Técnica

Las capas finales de Inception v3 preentrenadas identifican objetos generales, pero no discriminan micro-variaciones en rostros. El *Fine-Tuning* profundo fue estrictamente necesario para adaptar la red a este dominio morfológico.

Impacto del fine-tuning De 37.6 % a 55.7 % de accuracy, F1 de 0.36 a 0.55



Curvas de entrenamiento Precisión y error por época



Hallazgos / Insights

Lo Positivo
El rostro **Rectangular** presenta la morfología más fácil de aislar e identificar (alcanzando un Recall del 71.1%).

La Limitación
El rostro **Cuadrado** es el de mayor complejidad. Aunque mejoró drásticamente del 16% al 48.7% con el *Fine-Tuning*, el modelo aún lo confunde frecuentemente con las formas Ovaladas y Redondas.

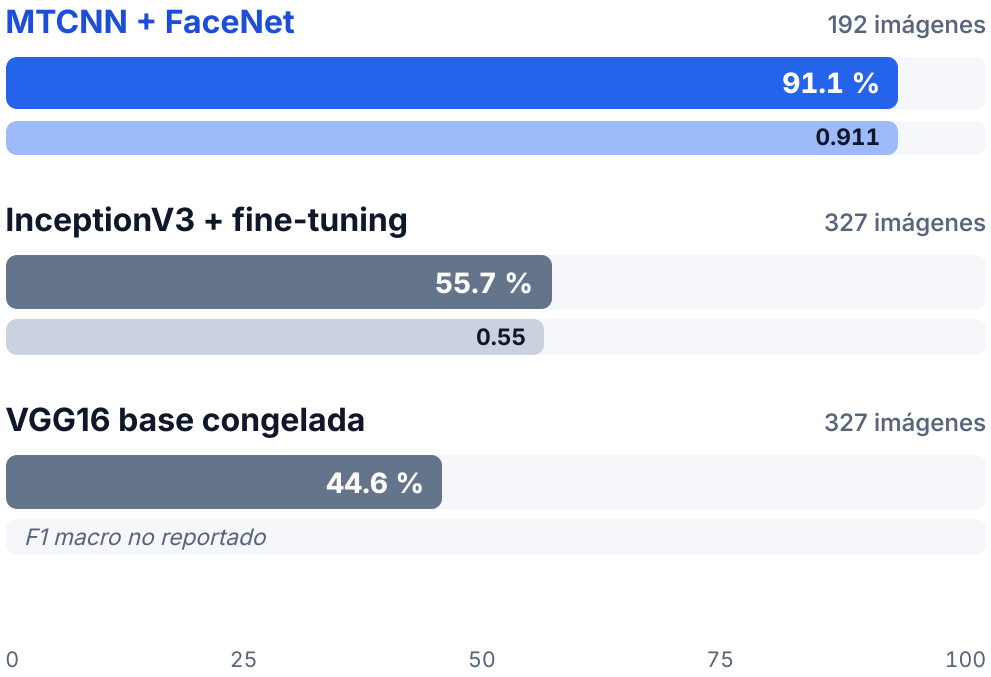
La Causa
Las fronteras visuales entre mandíbulas cuadradas y ovaladas generan ruido computacional. Elementos externos como distintos ángulos fotográficos o la presencia de barbas interrumpen la extracción de bordes en las CNNs convencionales.

Análisis de errores por clase Cuadrado sigue siendo la clase más compleja

Comparación de los tres métodos

Mejor configuración de cada método

Accuracy en test (%) F1 macro (× 100)



MÉTODO	ACCURACY	F1 MACRO	PREENTRENO	AJUSTE FINO
MTCNN + FaceNet	91.1 %	0.911	VGGFace2	Sí
InceptionV3	55.7 %	0.55	ImageNet	Sí, desde capa 249
VGG16	44.6 %	*No reportado*	ImageNet	No

⚠ **Lectura correcta:** FaceNet se evaluó sobre 192 imágenes y los otros dos sobre las mismas 327. La ventaja de 35.4 puntos es amplia, pero no proviene de un test idéntico; se confirmará en la siguiente etapa.

✓ **MTCNN + FaceNet obtuvo el mejor desempeño** en accuracy y en F1 macro. El preentrenamiento en rostros marca la diferencia frente a ImageNet.

Conclusiones y trabajo faltante

Modelo seleccionado para la siguiente etapa

MTCNN + FaceNet

Elegido por su **rendimiento experimental:** 91.1 % de accuracy y F1 macro de 0.911, a 1.2 puntos del 92.32 % del artículo de Ji.

Conclusiones

- **El preentrenamiento facial pesa más que la arquitectura:** VGG16 e InceptionV3, entrenadas en ImageNet, no superan el 56 % con unas 1,000 imágenes.
- **El fine-tuning ayuda, pero no alcanza:** InceptionV3 sube de 37.6 % a 55.7 %.
- **El preprocesamiento es decisivo:** la detección y el recorte previos eliminan el ruido del torso y del fondo, y el aumento de datos debe ser restrictivo.

Trabajo faltante: 3.ª entrega

- **Reevaluar los tres modelos** sobre la misma partición de test para confirmar la selección.
- **Integrar el motor de reglas** que recomienda de uno a dos cortes por morfología.
- **Desplegar la inferencia** en tiempo real con Gradio o Streamlit.

Vistazo a los notebooks

Cada desarrollo está disponible para ejecutarse. Abre el enlace o escanea el código.

Método 1

Seleccionado

MTCNN + FaceNet

Google Colab

colab.research.google.com/drive/10xD4vZUbmNu71s9rLm1zdyxq3R_UcTTQ

Abrir notebook ↗

Método 2

VGG16

Google Colab

colab.research.google.com/drive/1Ag0TpQLSSVMN4O3cOH7zK9PeDfpAgYs7

Abrir notebook ↗

Método 3

InceptionV3

Google Drive

drive.google.com/file/d/1HIyRgBE8mN2cKhges_o2WarfzalrBJ2Q

Abrir notebook ↗